Imię i nazwisko	Przedmiot, kierunek, grupa	Temat projektu	Data
Paulina Reichel	Podstawy sztucznej inteligencji. Inżynieria obliczeniowa. Gr.2	Budowa i działanie perceptronu	26.10.2018

Cel projektu:

Poznanie budowy i działania perceptronu poprzez implementację oraz uczenie perceptronu realizującego wybraną funkcję logiczną dwóch zmiennych.

Realizacja zadania:

- Implementacja sztucznego neuronu według odpowiedniego algorytmu
- Wygenerowanie danych uczących i testujących funkcji logicznej dwóch zmiennych
- Uczenie perceptronu
- Testowanie perceptronu

Opis teoretyczny:

Perceptron- jest to najprostsza sieć neuronowa, składająca się z jednego bądź wielu niezależnych neuronów. Perceptron prosty ma budowę: d → 1 → 1, tzn. d neuronów wejściowych, 1 neuron ukryty i 1 wyjście. Aktywacja neuronu ukrytego jest bezpośrednio wyprowadzana na wyjście.

Graficzne przedstawienie perceptronu:

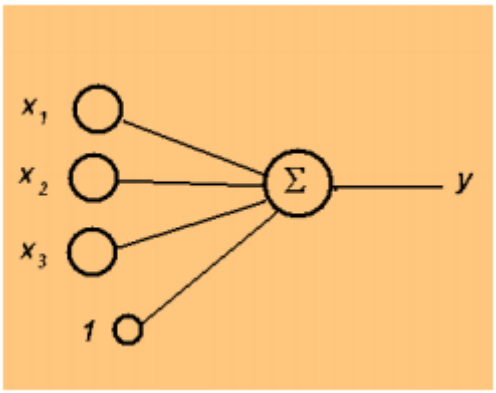

Postacie funkcji aktywującej perceptron:

- Funkcja progowa (perceptron progowy):

$$\phi(s) = \begin{cases} 0 & s < p \\ 1 & s \geq p \end{cases}$$

- Funkcja znakowa:

$$\phi(s) = \begin{cases} -1 & s < p \\ +1 & s \geq p \end{cases}$$

- Sigmoida

$$\phi(s) = \sigma(s) = \frac{1}{1 + exp(-\beta s)}$$

- Symetryczna sigmoida $(\lim_{x\to-\infty}\phi=-1)$

$$\phi(s)=\frac{1-\exp(-\beta s)}{1+\exp(-\beta s)}$$

Algorytm uczenia sieci to proces dochodzenia wag do wartości optymalnych to znaczy zapewniających odpowiednie reakcje sieci na pokazywane jej sygnały wejściowe, czyli prawidłowe rozwiązanie zadań. Istnieje kilka sposobów doborów wag i uczenia perceptronu, np. simple perceptron learning algorithm, pocket learning algorithm, pocket algorithm with ratchet. Projekt skupia się na perceptronie Rosenblatta, więc wystarczy zastosować algorytm uczenia perceptronu prostego.

Kroki wykonanego programu:

- Utworzenie za pomocą funkcji newp(pr,s,tf,lf) nowego perceptronu, gdzie pr to macierz wartości, s-liczba neuronów, tf -funkcja transferu,a lf to funkcja uczenia.
- Wygenerowanie na podstawie działania bramki logicznej AND parametru określającego wagi perceptronu uczącego

X1	0	0	1	1
X2	0	1	0	1
t	0	0	0	1

- Inicjalizacja wag oraz wykorzystanie funkcji „init” do inicjalizacji dowolnymi parametrami
- Wykorzystanie funkcji simulink, przyjmującej jako argumenty model (zainicjowany funkcją „init”) oraz wagę, do stworzenia symulacji
- Ustalenie liczby epok (maksymalnie mogą wynosić 20)
- Wykorzystanie funkcji train do uczenia perceptronu
- Otrzymanie wyniku symulacji przed i po uczeniu

Kod programu (Matlab)

```
%%
close all; clear all; clc;

net=newp([0 1; -2  2],1);
x = [0 0 1 1; 0 1 0 1];
t = [0 0 0 1];
net = init(net);
before=sim(net,x);
net.trainParam.epochs=15
net = train(net,x,t);
after=sim(net,x)
```

Otrzymane wyniki:

Dla parametru t=[0 0 0 1] (bramka logiczna AND)

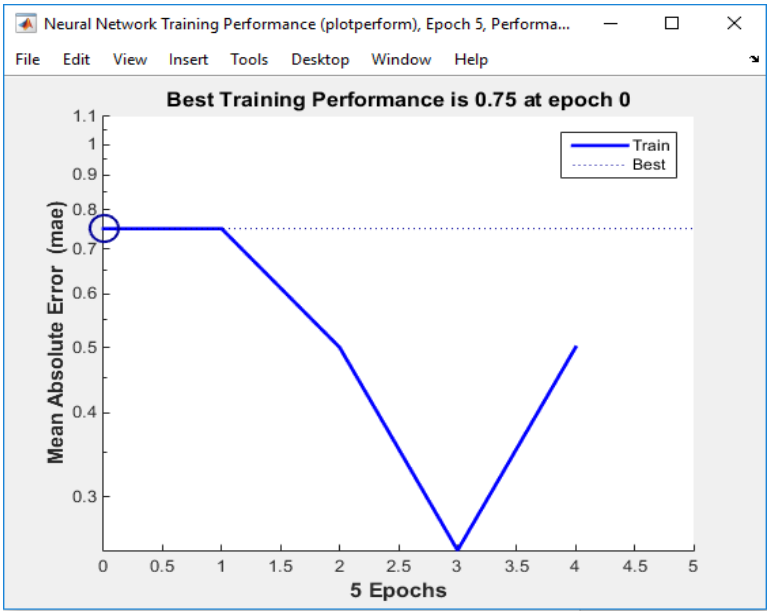

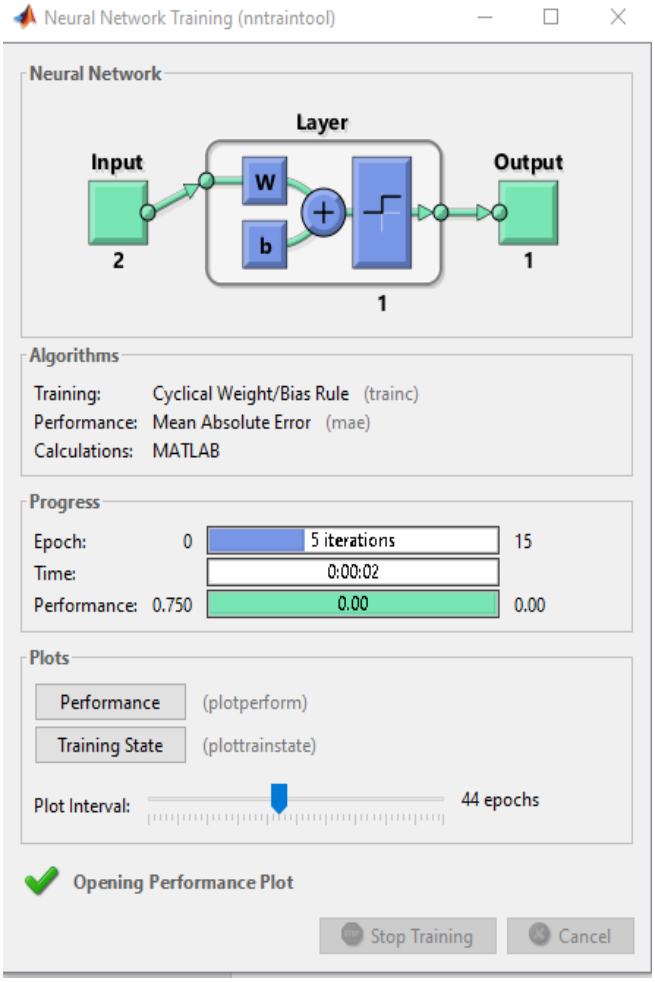


```
before =

     1     1     1     1

after =

     0     0     0     1
```

Dla parametru t=[1 1 1 0]

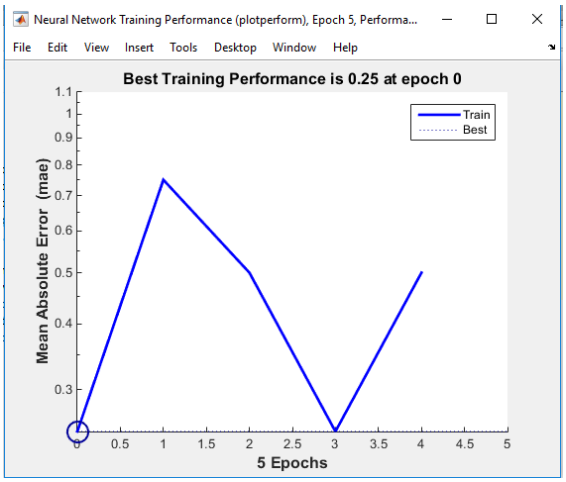

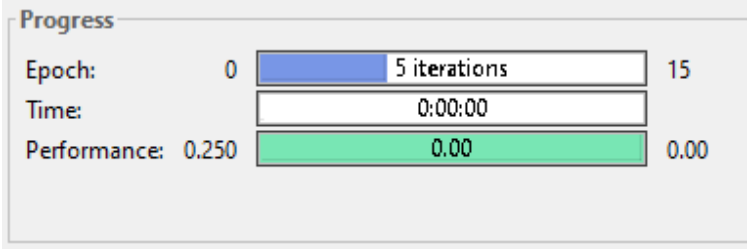

Dla parametru t=[0 1 1 0] oraz t=[1 0 0 1]

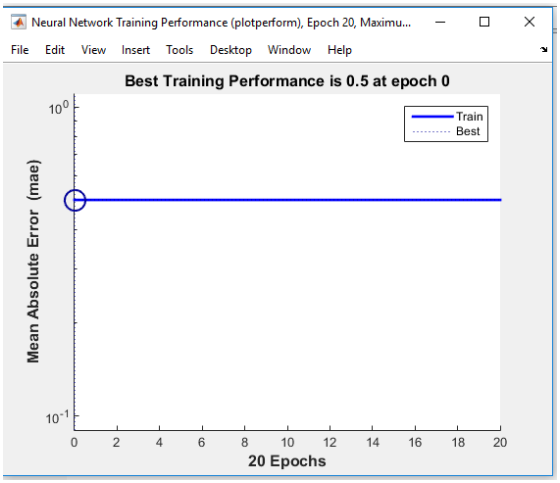

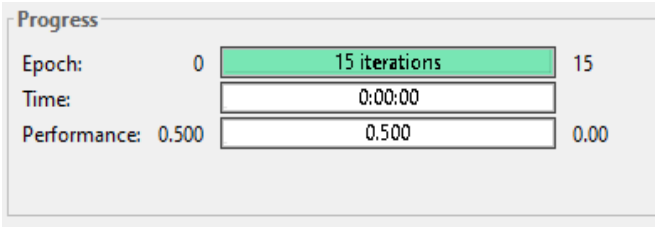

Dla parametru t= [0 1 1 1]

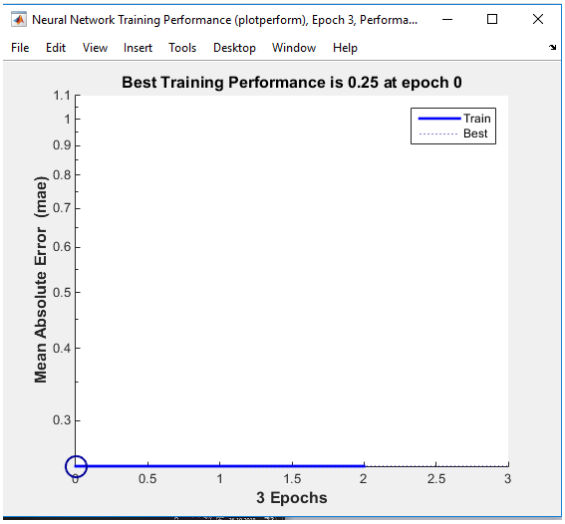

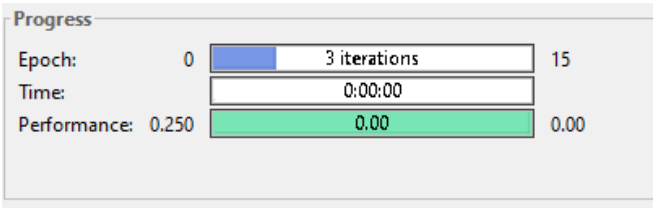

Parametr t	czas	Liczba neuronów	Wsp.mae	Ilość inicjalizacji potrzebnych do nauczenia perceptronu
[0 0 0 1]	0:00:02	1	0.75	5
[1 1 1 0]	0:00:00	1	0.25	5
[1 0 0 1]	0:00:00	1	0.5	15
[0 1 1 1]	0:00:00	1	0.25	3
[0 0 0 1]	0:00:02	6	0.75	5
[1 1 1 0]	0:00:00	6	0.25	5
[1 0 0 1]	0:00:00	6	0.5	15
[0 1 1 1]	0:00:00	6	0.25	3

Analiza błędów:

Analizę błędów można przeprowadzić za pomocą funkcji MAE, która jest funkcją wydajności sieci. Mierzy wydajność sieci jako średnią bezwzględnych błędów. W przypadku programu wywoływanie funkcji w kodzie jest zbędne, a wartość funkcji błędu absolutnego wystarczy odczytać z wyżej zamieszczonego wykresu. Używając bramki logicznej AND w epoce zerowej współczynnik błędu wynosi 0.75, w pierwszej epoce błąd zaczyna maleć, dochodząc do zera w epoce trzeciej. To miejsce, jest momentem nauczenia sieci . Przy użyciu bramki NAND współczynnik był dużo niższy i wynosił 0,25, jednak podobnie jak w przypadku AND nauczenie perceptronu zaszło w 3 epoce. Użycie bramki XOR nie dało wiarygodnych wyników.

Wnioski:

- Zadania zamieszczone w projekcie zostały zrealizowane
- Wykonanie zadania umożliwiło poznanie ogólnej zasady algorytmu uczenia perceptronu.
- Bramka logiczna ma duży wpływ na MAE.
- Za pomocą perceptronu prostego można rozwiązywać tylko problemy separowalne liniowo (np. bramka XOR powoduje powstanie konfliktu rozwiązywalnego).
- Funkcja train zawarta w pakiecie Matlab znacznie ułatwiła problem nauczenia sieci
- Uczenie perceptronu nastąpiło w 3 epoce.
- Na algorytm przeznaczone było 15 epok, lecz do nauczenie nastąpiło już 5 inicjalizacji.
- Maksymalne MAE wyniosło 0.75 (w epoce zerowej)
- W pierwszej epoce MAE zaczęło maleć, do osiągnięcia zera w 3 epoce.
- Podany algorytm okazał się wystarczający do nauczenia perceptronu prostego, lecz w przypadku bardziej skomplikowanych sieci neuronowych, może okazać się zbyt prymitywny
- Dzięki temu, że wejścia i wyjścia mogą przyjmować tylko kilka wartości, są tylko 4 możliwości zmiany wag, a każda zmiana wagi skutkuje tym, że po ponownym podaniu tego samego przykładu odpowiedź była bliższa pożądanej (uczenie sieci neuronowej).
- W zależności od zastosowanej bramki logicznej następuje zmiana wszystkich wyników- czasu, epoki, w której zostaje nauczony perceptron oraz wartość funkcji błędu absolutnego.
- Liczba neuronów nie ma wpływu na szybkość uczenia się perceptronu